

MIHA THE MIGHTY 3.AUT2 AUTOMATIKA 003612345678	FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA ZAGREB ZAVOD ZA AUTOMATIKU I RAČUNALNO INŽENJERSTVO	17.6.2012.
	Osnove inteligentnog upravljanja	
	Domaća zadaća br. III: Podešavanje neizrazitog regulatora metodom samoučenja	

Uvod

U današnjim sustavima automatskog upravljanja adaptivno upravljanje ima veliku i važnu ulogu. Kroz životni vijek procesa mogu se desiti kontinuirane ili čak i nagle promjene parametara procesa. Također, moguće su promjene uvjeta u okolini procesa (vanjski uvjeti), čak i načina rada samog procesa kroz vrijeme. Prvobitno projektirani regulator u tim slučajevima neće više pokazivati dobra svojstva i davati zadovoljavajuće odzive - tada u igru ulazi adaptivno upravljanje. Primjerice, avion u letu kontinuirano gubi masu sagorijevajući gorivo – imamo nove parametre aviona. Kada te te promijene nisu nagle i velikih razmjera, procesom i dalje možemo upravljati na standardni način – povratnom vezom i standardnim algoritmima upravljanja. U slučajevima kada obični kontroleri ne mogu postići dovoljno dobru kvalitetu upravljanja procesom moramo imati određenu adaptaciju algoritma upravljanja kako bi se naš regulator prilagodio danim promjenama u sustavu. Adaptivni algoritam upravljanja može se jako dobro primijeniti na podešavanje neizrazitog regulatora. Znajući odziv kakav želimo imati (odziv referentnog modela sustava) i trenutni odziv našeg reguliranog sustava možemo koristeći adaptivni algoritam postići automatizirano podešavanje izlaznih singletona našeg neizrazitog regulatora. Cilj ove domaće zadaće je pomoću takvog algoritma podesiti naš fuzzy regulator, kako bi kako bi pomoću njega što bolje upravljali našim nepoznatim sustavom, odnosno kako bi odziv sustava što bolje približili referentnom modelu.

Teoretski prikaz i razrada

U sklopu ove domaće zadaće koristimo neizraziti regulator tipa sugeno nultog reda, koji kao izlazne skupove ima singleton, odnosno neizrazita pravila iz posljedičnog dijela regulatora imaju konstantu kao izlaznu funkciju. Na takav regulator primjenjuje se algoritam adaptiranja baze neizrazitih pravila primjenom referentnog modela i modela osjetljivosti. Regulator ao ulaz prima dvije varijable – to su signal pogreške $e(k)=u_r(k) - y(k)$ i signal promjene izlaza $dy= y(k)-y(k-1)$. Regulator pokazuje bolje ponašanje pri skokovitoj promjeni reference ako koristimo promjenu izlaznog signala dy umjesto standardne promjene signala pogreške Δe . Drugim riječima, kada bi promjena signala pogreške Δe doživljavala velike promjene, dy neće. U ostatku vremena Δe i dy su identičnog iznosa ali suprotnog predznaka. Svaka ulazna varijabla neizrazitog regulatora je definirana sa sedam različitih neizrazitih skupova opisanih Gaussovom funkcijom na kojima je primijenjen tzv. α -rez. Primjenom α -reza izbjegavano redundantno aktiviranje funkcija pripadnosti koje bi imale vrlo mali utjecaj (manji upravo od te vrijednosti α). Treba imati u vidu da Gaussova funkcija kao takva je veća od nule na čitavom \mathbb{R} . Koristimo neizrazitu implikaciju tipa produkt, dok je neizrazita agregacija tipa suma, odnosno koristimo COG metodu. Jezične vrijednosti ulaznih varijabli koje ćemo koristiti su: veliko negativno (VNE i VNDY), srednje negativno (SNE i SNDY), malo negativno (MNE i MNDY), okolica nule (ZE i ZDY), malo pozitivno (MPE i MPDY), srednje pozitivno (SPE i SPDY) i veliko pozitivno (VPE i VPDY). Tablica pravila dana je tablicom 1.

dy/e	VNE	SNE	MNE	ZE	MPE	SPE	VPE
VNDY	A ₁₁	A ₂₁	A ₃₁	A ₄₁	A ₅₁	A ₆₁	A ₇₁
SNDY	A ₁₂	A ₂₂	A ₃₂	A ₄₂	A ₅₂	A ₆₂	A ₇₂
MNDY	A ₁₃	A ₂₃	A ₃₃	A ₄₃	A ₅₃	A ₆₃	A ₇₃
ZDY	A ₁₄	A ₂₄	A ₃₄	A ₄₄	A ₅₄	A ₆₄	A ₇₄
MPDY	A ₁₅	A ₂₅	A ₃₅	A ₄₅	A ₅₅	A ₆₅	A ₇₅
SPDY	A ₁₆	A ₂₆	A ₃₆	A ₄₆	A ₅₆	A ₆₆	A ₇₆
VPDY	A ₁₇	A ₂₇	A ₃₇	A ₄₇	A ₅₇	A ₆₇	A ₇₇

Tablica 1. Tablica pravila neizrazitog regulatora

Adaptivni algoritam upravljanja koristi zadani referentni model s kojim opisujemo željeno ponašanje sustava. Cilj je dobiti što točnije slijeđenje referentnog modela. U ovoj domaćoj zadaći koristimo referentni model drugog reda, odnosno prijenosna funkcija referentnog modela u frekvencijskoj domeni dana je izrazom:

$$G_M(s) = \frac{\omega_n^2}{s^2 + 2\zeta\omega_n s + \omega_n^2},$$

gdje je: ζ faktor prigušenja, ω_n prirodna frekvencija modela.

Parametri referentnog modela izračunavaju se direktno iz pokazatelja kvalitete procesa, vremena prvog maksimuma (t_m) i nadvišenja (σ_m), po svima poznatim relacijama :

$$\zeta = \sqrt{\ln^2 \frac{\left(\frac{\sigma_m[\%]}{100}\right)}{\pi^2 + \ln^2 \left(\frac{\sigma_m[\%]}{100}\right)}},$$

$$\omega_n = \frac{\pi}{t_m \sqrt{1 - \zeta^2}}.$$

Adaptivni algoritam u svojim proračunima koristi pogrešku slijeđenja referentnog modela. Spomenuta pogreška služi kao indikator koliko se vladanje našeg reguliranog sustava približilo vladanju referentnog modela drugog reda. Pogreška slijeđenja referentnog modela definirana je kao:

$$e_M(k) = y_M(k) - y(k).$$

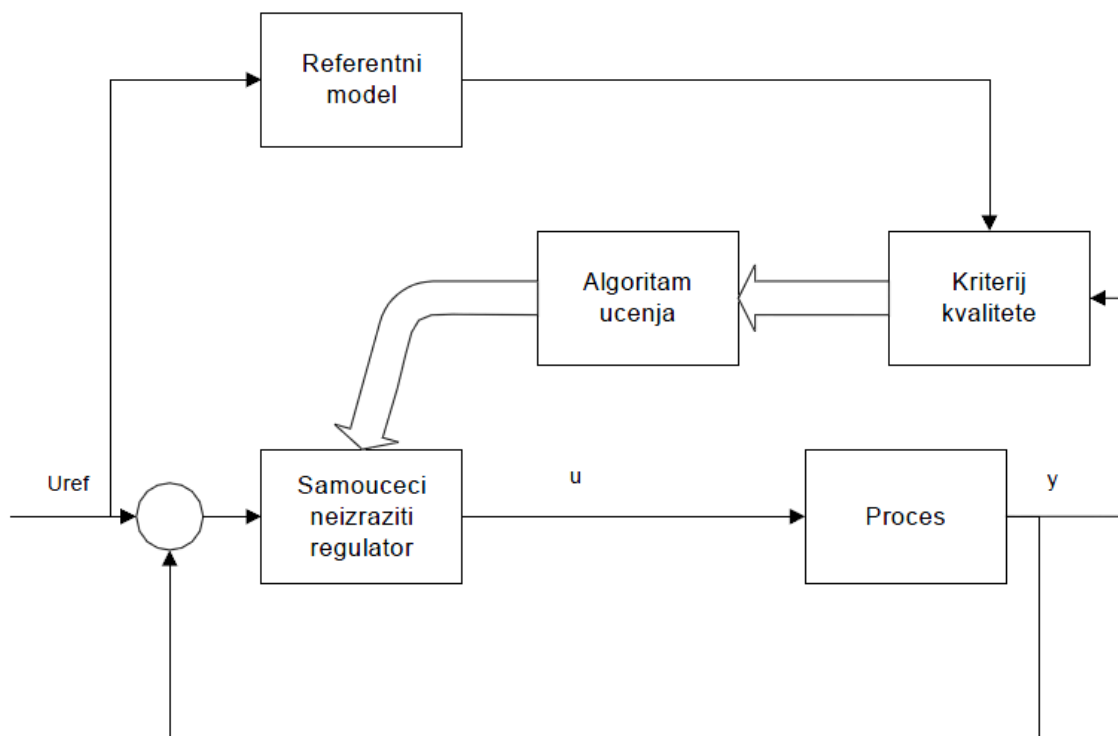
Krajnji zadatak podešavanja našeg neizrazitog regulatora je minimizacija pogreške slijeđenja referentnog modela. Adaptivni algoritam koristi uzastopne skokovite promjene reference kako bi mogao usporediti odziv referentnog modela i promatranog procesa. Jednom po iteraciji učenja podešava se pojedini parametar SNR-a (samoučeći neizraziti regulator). Bitno je napomenuti da se iteracijom smatra interval između dvije promjene referentnog signala. Promjena pojedinog upravljačkog pravila dana je slijedi iz izraza:

$$\Delta A_j^\kappa(k) = \frac{e_M^\kappa(k) - \sum_{(i=1, i \neq j)}^r \eta_{A_i}^\kappa \cdot \Delta A_i}{\eta_{A_j}^\kappa(k)}$$

gdje je : κ trenutna iteracija učenja, η funkcija osjetljivosti za pojedini parametar.

Korisno je napomenuti da se promjena parametra uobičajeno radi u slučaju kada je utjecaj tog parametra na izlaznu veličinu procesa najveći. Očekivano, utjecaj parametra je najveći kada je funkcija osjetljivosti najveća moguća – što se lako vidi iz gornje jednadžbe. Drugim riječima, u gornjem izrazu umjesto $\eta_{A_j}^\kappa$ možemo pisati $\max[\eta_{A_j}^\kappa(k)]$. Kako je riječ o iterativnom postupku promjena jednog parametra utječe na funkcije osjetljivosti ostalih parametara, odnosno nije poželjno raditi promjenu više parametara odjednom.

Shema kruga upravljanja dana je slikom 1.



Slika 1: Shema kruga upravljanja za adaptivno učenje

Upravo iz sheme na slici 1. možemo vidjeti ranije opisani način rada ovakvog sustava. Vidljivo je da kao kriterij kvalitete može biti bilo što u našem slučaju to je obična razlika odziva referentnog modela i upravljanog sustava.

Pristup rješenju danog problema

Zadatkom nam je zadan nepoznati proces koji predstavlja poziciju loptice na platformi. Za taj proces potrebno je projektirati neizraziti regulator pomoću SLFCL bloka (skraćeno od Self-learning Fuzzy Logic Controller). Upravo u tom bloku u Simulinku je implementiran algoritam za podešavanje našeg neizrazitog regulatora. Iznimno je bitno paziti na određivanje raspona ulaznih veličina u regulator (ulazne funkcije su definirane na intervalu $[-1,1]$) tj. moramo ih sukladno tome skalirati. Jednako tako, moramo paziti i na tip procesa koji imamo (astatički ili statički).

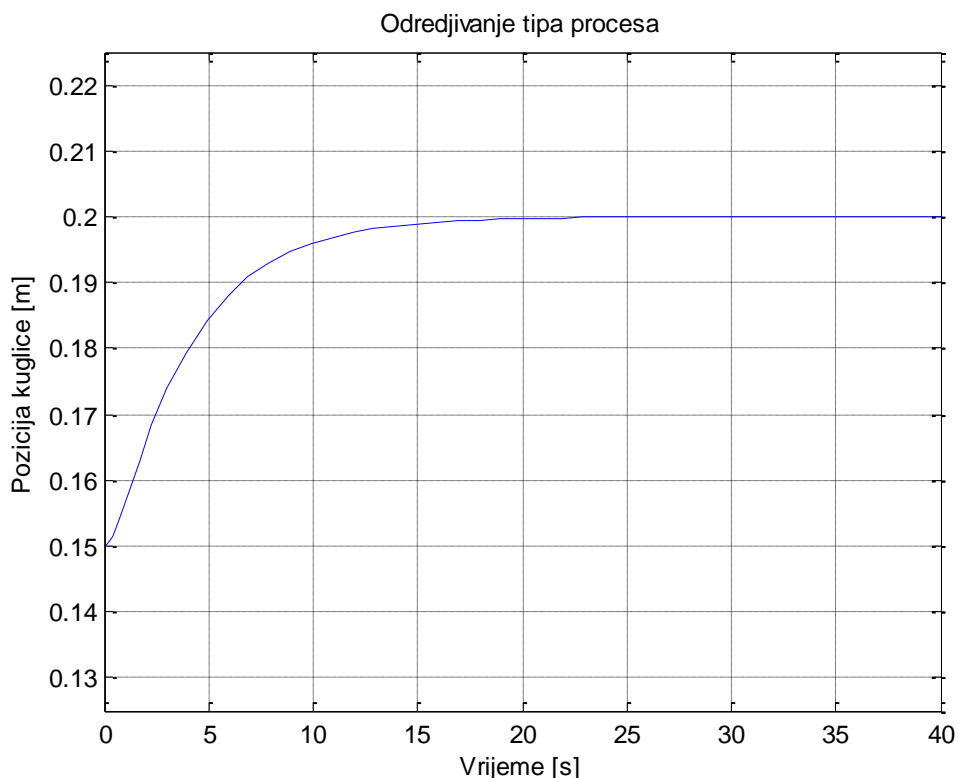
U sklopu ove zadaće od nas se traži:

- eksperimentalno odrediti tip procesa
- odrediti raspon pogreške e i izlaza sustava y pri promjeni reference od 4 cm, te podesiti skaliranje ulaza regulatora da radi u punom rasponu pri promjeni reference od 4 cm
- podesiti referentni model da ima vrijeme prvog maksimuma u $t_m = 2s$ i nadvišenje $\sigma_m = 10\%$
- dodatno ispitivati utjecaj pojedinih parametara na brzinu i kvalitetu učenja
- ispitati odziv na referencu koja je 3 puta veća one za koju smo projektirali sustav
- ispitati ponašanje regulatora na periodičkom signalu

Rješenje danog problema

Identifikacija tipa procesa

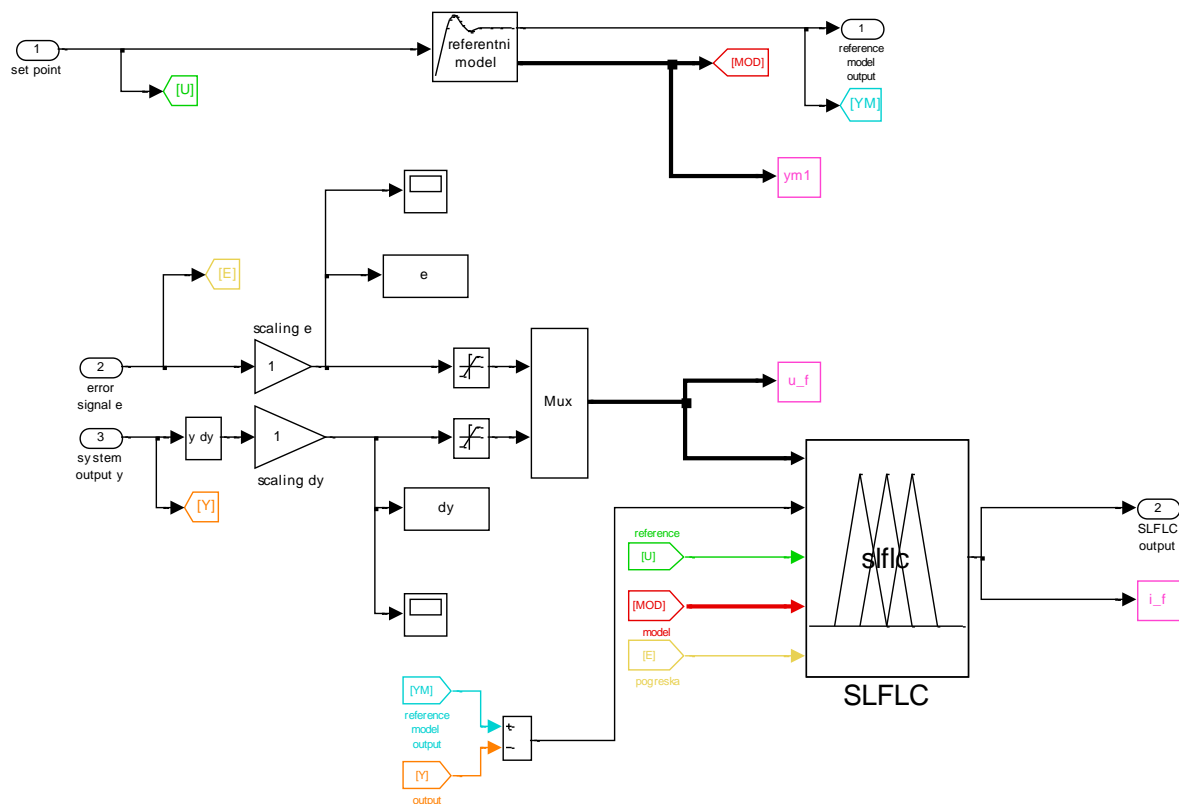
Prvo što moramo napraviti je identificirati kakav proces imamo. Proces može biti statički ili astatički. Astatički procesi u sebi imaju integralno djelovanje, odnosno oni imaju jedan pol u $s = 0$. Takav tip procesa na skokovitu promjenu reference nema pogreške u stacionarnom stanju, tj. $e = 0$. S druge strane, statički procesi nemaju spomenuto integralno djelovanje, dakle oni će imati pogreške u stacionarnom stanju pri skokovitoj promjeni reference. Da bi eksperimentalno pokazali kakav je naš proces sve što moramo napraviti je dovesti skokovitu promjenu reference na ulaz i ako se pokaže da nema odstupanja u stacionarnom stanju, onda znamo da je naš sustav astatički, inače je statički.



Slika 2: Određivanje tipa procesa

Slikom 2. prikazan je odziv našeg nepoznatog procesa na skokovitu pobudu konačnog iznosa 0.2 m. Iz odziva je vidljivo da nema pogreške u stacionarnom stanju – zaključujemo da je naš proces astatički.

Određivanje raspona promjene signala pogreske e i izlaza iz sustava dy



Slika 3: Simulacijska shema

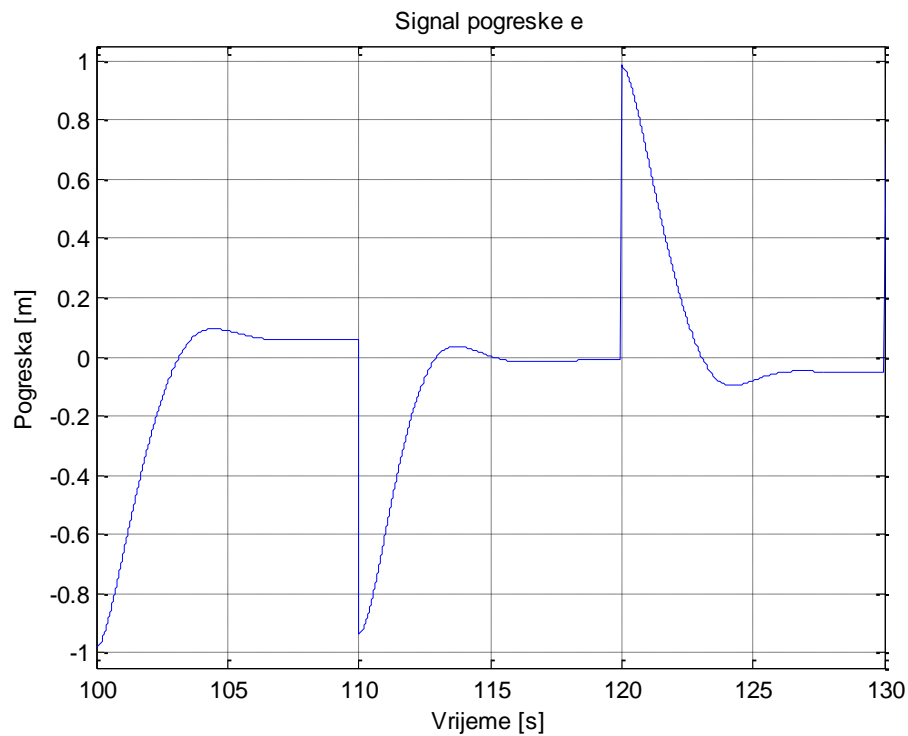
Promatramo signale e i dy bez skaliranja (pojačanja „ scaling e “ i „scaling dy “ su jedinična). Promjena reference je 4 cm. Tražimo maksimalne promjene navedenih signala. Dobivene promjene su :

- za signal pogreške e maksimalna vrijednost je bila 0.0402
- za signal promjene izlaza dy maksimalna vrijednost je bila 0.000306413

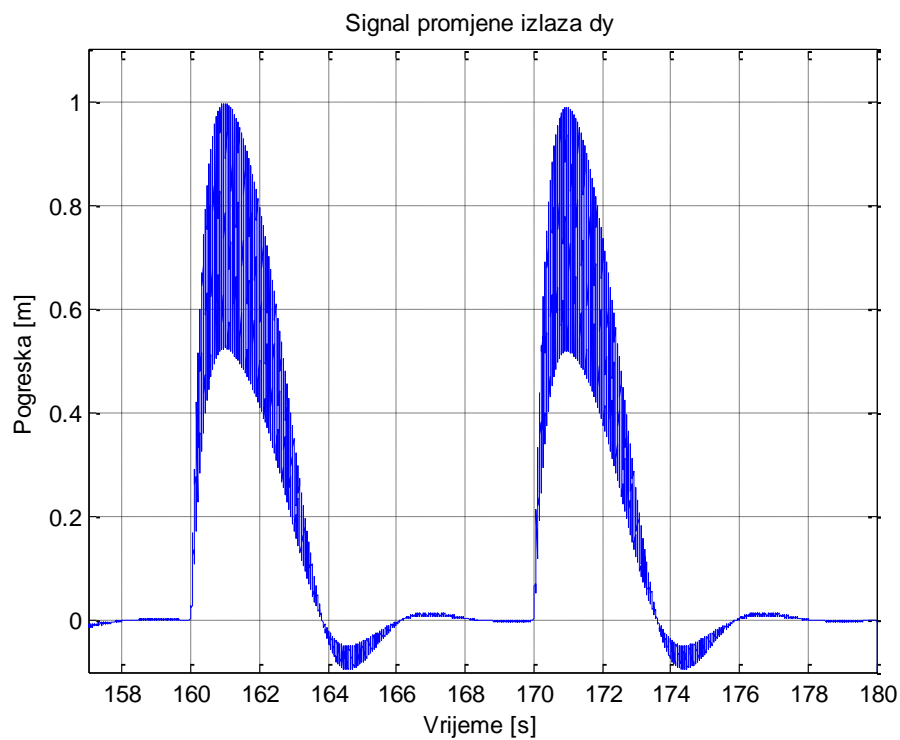
Shodno tome moramo odabrati koeficijente skaliranja koji će osiguravati da se sve vrijednosti nalaze unutar granica $[-1,1]$. Logičan odabir koeficijenata skaliranja bi bio $1/\text{max_vrijednost_pojednog_signala}$ odnosno :

- scaling_e = $1/0.0402 = 24.8756$
- scaling_dy = $1/0.000306413 = 3263.5683$

Napomenimo još da su gornje vrijednosti koeficijenata skaliranja dobivene uz nepromijenjene vrijednosti unutar SLFLC bloka. Slike skaliranih signala e i dy će biti priložene kasnije uz korektno odabrane parametre SLFLC bloka.



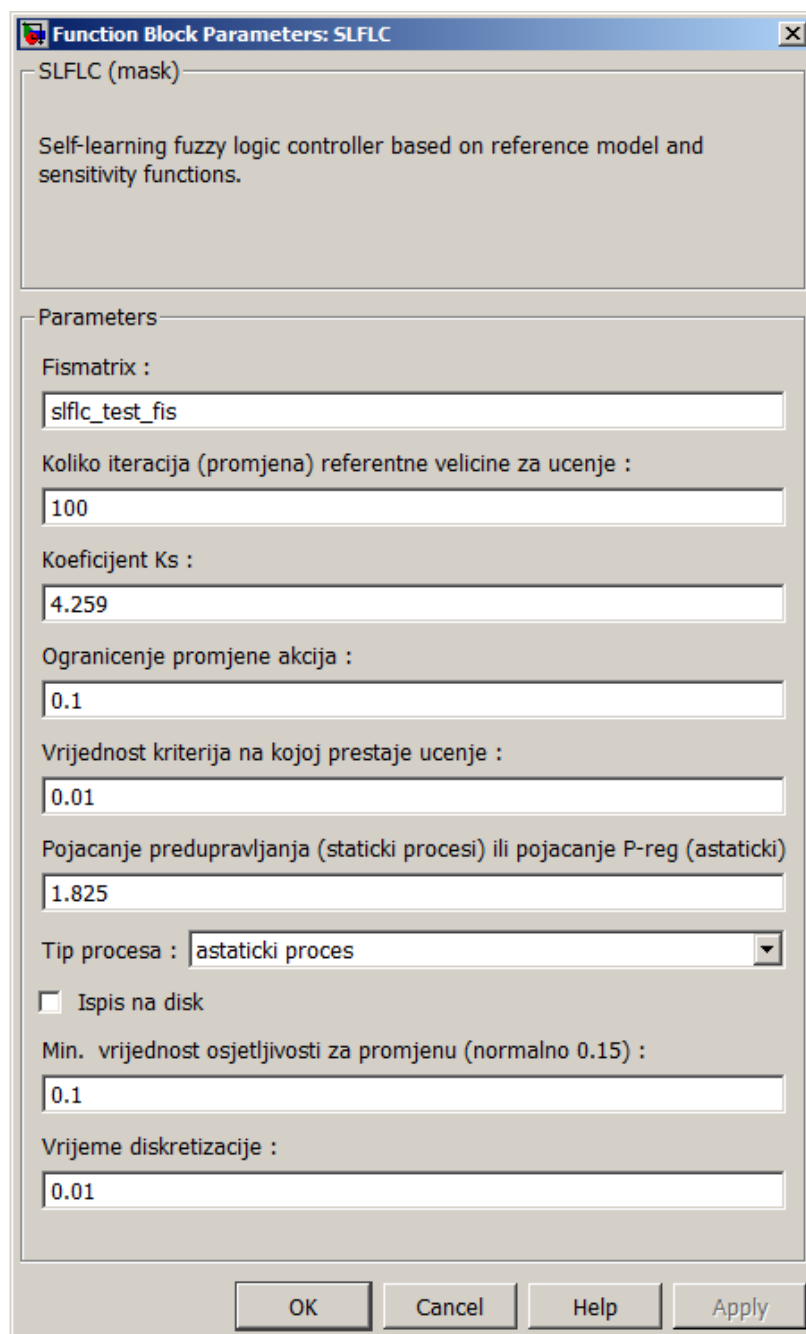
Slika 4: Skalirani signal pogreške e



Slika 5: Skalirani signal promjene izlaza dy

Podešavanje parametara SLFLC bloka

U nastavku slijedi objašnjenje što pojedini parametar SLFLC bloka predstavlja i kako on utječe na brzinu i kvalitetu učenja – navedeni zaključci su teorijski ali su i empirijski ispitani. [1]



Function Block Parameters: SLFLC

SLFLC (mask)

Self-learning fuzzy logic controller based on reference model and sensitivity functions.

Parameters

Fismatrix :
slflc_test_fis

Koliko iteracija (promjena) referentne velicine za učenje :
100

Koeficijent Ks :
4.259

Ogranicenje promjene akcija :
0.1

Vrijednost kriterija na kojoj prestaje učenje :
0.01

Pojacanje predupravljanja (staticki procesi) ili pojacanje P-reg (astaticki)
1.825

Tip procesa : astaticki proces

☐ Ispis na disk

Min. vrijednost osjetljivosti za promjenu (normalno 0.15) :
0.1

Vrijeme diskretizacije :
0.01

OK Cancel Help Apply

Slika 6: Početno stanje bloka SLFLC

Fismatrix – označava ime neizrazite matrice koju zadaje sam korisnik. Oblik je potpuno analogan obliku koji je definiran Fuzzy Logic Toolbox-om

Broj iteracija – ovaj parametar predstavlja broj promjena referentne veličine za koje će trajati učenje. Nakon dosegnutog broja promjene referentne veličine učenje će prestati i samoučeći neizraziti regulator će dalje raditi sa do tada naučenom upravljačkom tablicom. Veći broj iteracija povlači da će učenje trajati duže, ali nije nužno da će rezultati biti bolji (uz loše odabran Ks odziv nakon učenja može težiti k lošijem).

Koeficijent Ks – ovaj parametar nam određuje vrijednost faktora sigurnosti, koji je u neposrednoj vezi sa statičkim pojačanjem reguliranog procesa. Povećanjem vrijednosti koeficijenta Ks može se stabilizirati učenje. Povećanjem koeficijenta Ks samoučeći neizraziti regulator sporije "uči", odnosno sporije izgrađuje tablicu, ali je učenje stabilnije. Analogno tome uz manji Ks učenje ide brže, ali ono može biti nestabilno.

Ograničenje promjene akcija – ovaj koeficijent računamo prema idućoj formuli $\alpha = e^{(OGR \cdot |em|)}$. Ovaj koeficijent je sličan kao i Ks, učenje je sporije ako je OGR veći, a brže ako je manji. Također postoji ograničenje koje ne dopušta promjene akcija veće od 1.

Vrijednost kriterija kvalitete na kojoj prestaje učenje – kriterij kvalitete dan je jednadžbom :

$$E = \sum_i^{i+1} |e|$$

gdje je i početno vrijeme trenutne iteracije učenja, i+1 završetak trenutne iteracije učenja.

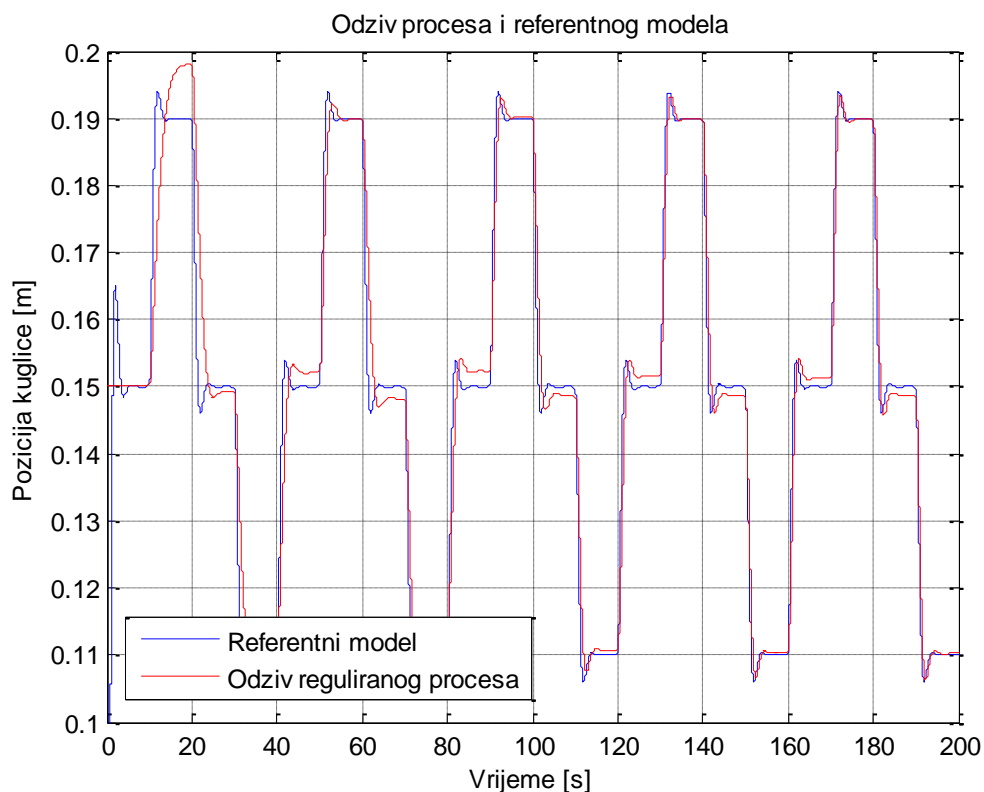
Pri svakoj skokovitoj promjeni referentne veličine tijekom učenja kriterij se postavlja u nulu. Ako učenje ide u dobrom smjeru onda vrijednost varijable E pada s vremenom.

Pojačanje predupravljanja - Vrijednost parametra Kp određuje pojačanje proporcionalnog regulatora, ako je izabrani tip procesa "astatički proces". U slučaju izbora vrijednosti parametra Kp=0 i tip procesa="astatički proces" (7. parametar), tada izlaz iz bloka SNR predstavlja samo upravljačku veličinu dobivenu iz SNR-a, tj. bez dodatnog djelovanja proporcionalnog regulatora. Ako je vrijednost parametara Kp=0, a tip procesa="statički proces" tada, budući da se koeficijent predupravljanja uči, izlaz iz samoučećeg neizrazitog


regulatora će biti kompozicija signala iz samoučećeg neizrazitog regulatora i dodatnog signala predupravljanja.

Min. vrijednost osjetljivosti za promjenu (normalno 0.15) - Ovaj parametar označava vrijednost praga funkcija osjetljivosti. Ako je maksimalna vrijednost parametra funkcije osjetljivost u promatranoj iteraciji učenja manja od praga vrijednosti funkcija osjetljivosti, tada se u toj iteraciji akcija samoučećeg neizrazitog regulatora vezana uz tu funkciju osjetljivosti neće promijeniti.

Prvo moramo učitati .fis datoteku koja sadrži 49 singletona svaki vrijednosti 0. Moramo upisati zahtijevane parametre referentnog modela (vrijeme maksimuma i nadvišenje). Pojačanje predupravljanja je pametno postaviti na vrijednost $1/\text{statičko_pojačanje_procesa}$, odnosno $1/0.4671 = 2.14087$. Treba paziti da se odabere ispravan tip procesa, u našem slučaju odabiremo opciju „astatički“. Koeficijent **Ks inicijalno postavljamo u 2**. Ostali parametri u bloku ostaju isti kao što su na slici 6. Dobiveni rezultati prikazani su slikama 7 i 8.



Slika 7: Odziv procesa i referentnog modela



Slika 8: Uvećani odziv procesa i referentnog modela

dy/e	VNE	SNE	MNE	ZE	MPE	SPE	VPE
VNDY	-0.120	-0.120	-0.063	0.008	0.000	0.000	0.000
SNDY	-0.120	-0.120	-0.034	0.089	0.000	0.000	0.000
MNDY	-0.120	0.119	-0.122	0.025	0.147	0.000	0.000
ZDY	-0.080	-0.100	-0.028	0.009	0.080	0.040	0.080
MPDY	0.000	0.000	0.116	0.006	0.131	0.120	0.124
SPDY	0.000	0.000	0.000	-0.100	0.054	0.112	0.120
VPDY	0.000	0.000	0.000	-0.004	0.045	0.112	0.080

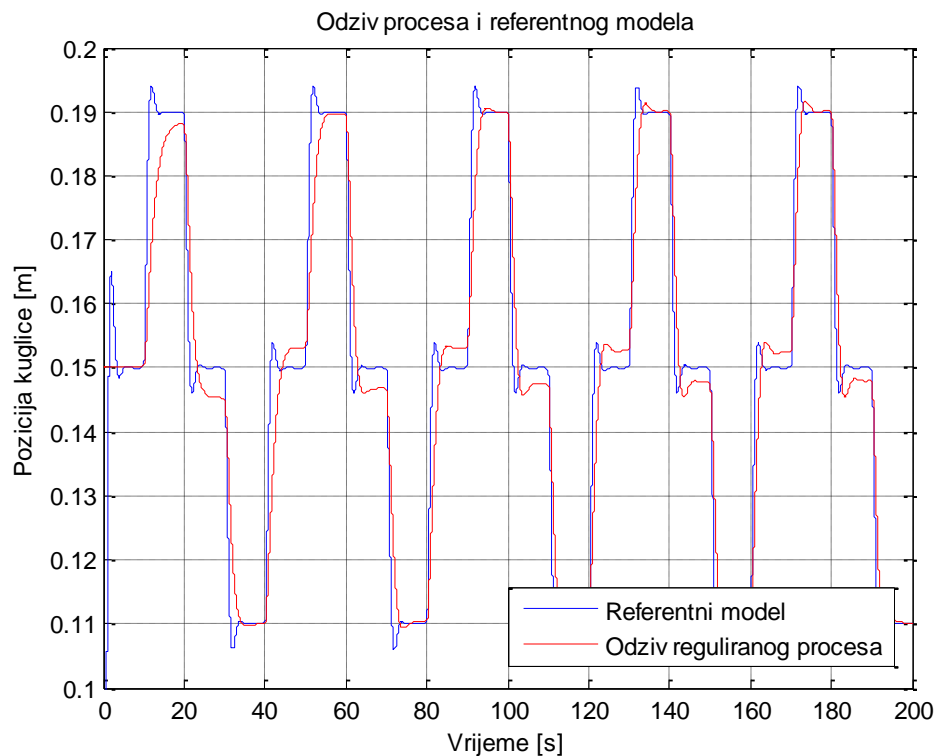
Tablica 2. Skup neizrazitih pravila uz $K_s=2$

U sklopu domaće zadaće ne traži se da izračunamo koliko je poklapanje referentnog modela i odziva reguliranog sustava. Radi kompletnosti navodim jednadžbu kojom sam računao sličnost ta dva odziva:


$$fit = \frac{(1 - norm(y_m - y))}{norm(y_m - mean(y_m))} \cdot 100$$

Za zadnju iteraciju dobio se $fit = 87.3416$, što je za ovakav proces jako dobro. Produženje trajanja simulacije daje i bolje preklapanje.

Prikažimo odzive za **Ks=10**, svi ostali parametri su nepromijenjeni. Uočavamo ranije spomenuto usporavanje učenja, ali stabilnije.



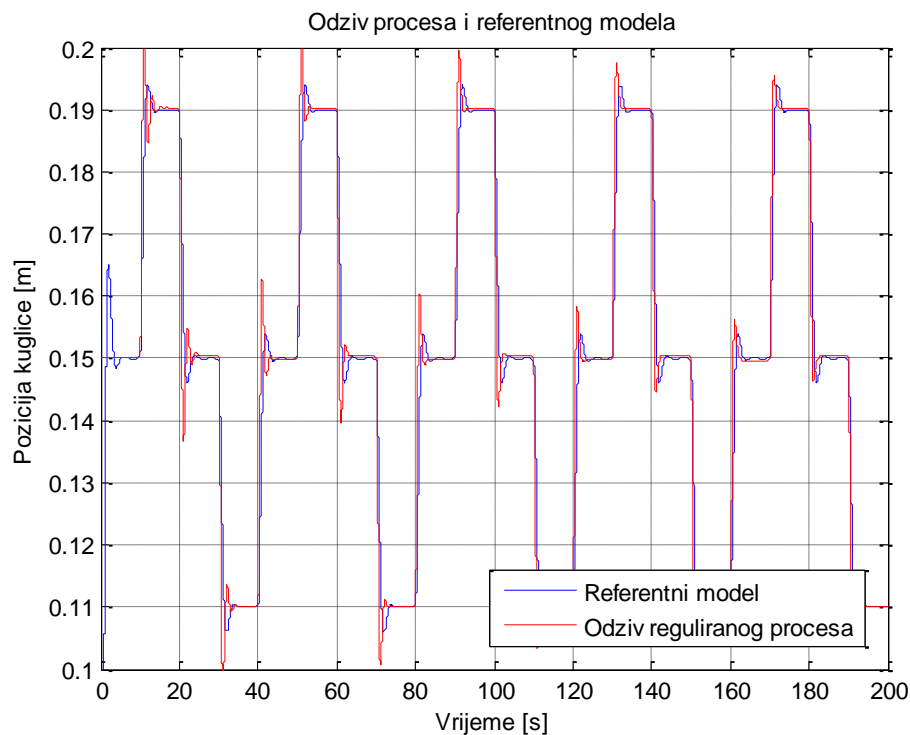
Slika 9: Odziv procesa i referentnog modela uz Ks= 10

Slika 10: Uvećani odziv procesa i referentnog modela uz $K_s = 10$

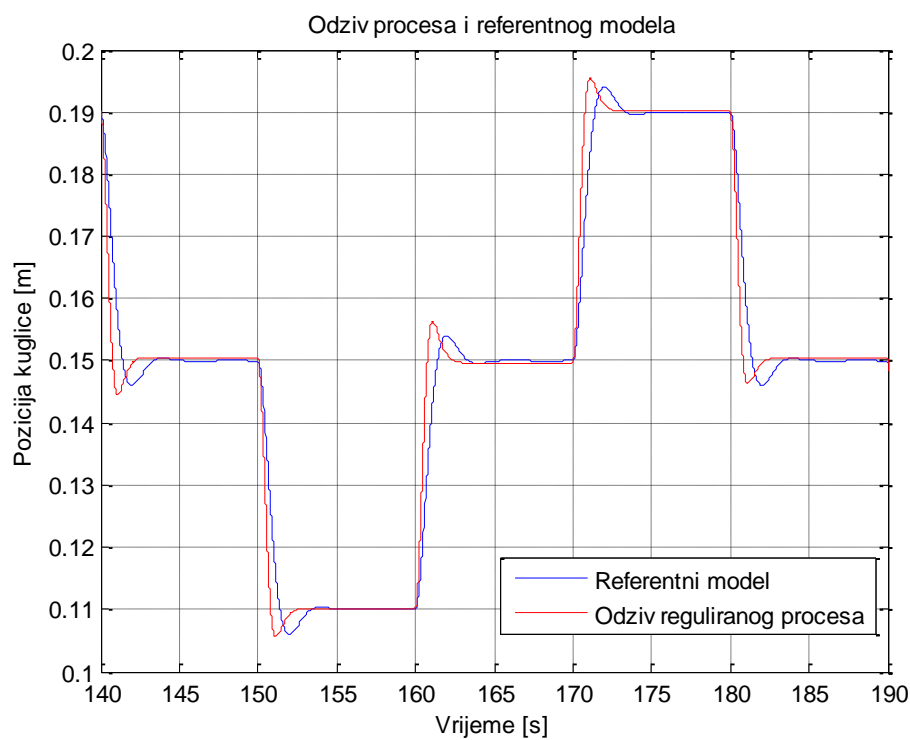
dy/e	VNE	SNE	MNE	ZE	MPE	SPE	VPE
VNDY	0.000	0.000	0.003	0.057	0.098	0.000	0.000
SNDY	0.000	0.008	-0.091	-0.029	0.047	0.060	0.000
MNDY	0.000	-0.136	-0.033	0.011	0.021	0.139	0.000
ZDY	-0.080	0.132	0.004	0.010	0.019	0.146	0.080
MPDY	0.000	-0.104	0.006	0.012	0.053	0.147	0.000
SPDY	0.000	-0.040	-0.038	0.054	0.108	-0.005	0.000
VPDY	0.000	0.000	-0.099	-0.046	-0.001	0.000	0.000

Tablica 3. Skup neizrazitih pravila uz $K_s = 10$

Na slikama 11 i 12 je odziv modela $K_s = 3$, no pojaćanje predupravljanja je povećano 10 puta koje sada iznosi $10/0.4671 = 21.4$.



Slika 11: Odziv procesa i referentnog modela uz pojaćanje predupravljanja = 21.4

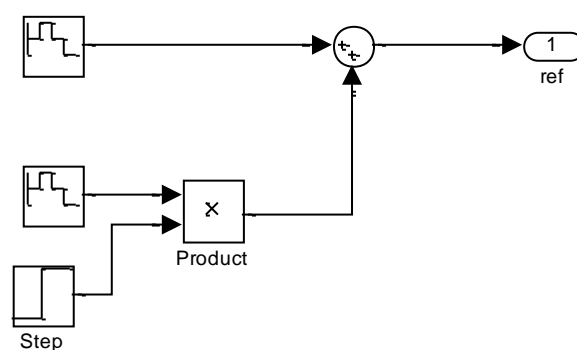


Slika 12: Uvećan odziv procesa i referentnog modela uz pojaćanje predupravljanja = 21.4


dy/e	VNE	SNE	MNE	ZE	MPE	SPE	VPE
VNDY	0.249	0.244	0.256	0.181	0.080	0.000	0.000
SNDY	0.250	0.243	0.320	0.241	0.080	0.000	0.000
MNDY	0.000	0.000	0.086	0.091	0.080	0.000	0.000
ZDY	0.000	0.000	0.039	-0.011	-0.063	0.000	0.000
MPDY	0.000	0.000	-0.170	-0.096	-0.194	0.000	0.000
SPDY	0.000	0.000	-0.040	-0.162	-0.280	-0.180	-0.180
VPDY	0.000	0.000	0.000	-0.083	-0.208	-0.180	-0.180

Tablica 4. Skup neizrazitih pravila uz pojacanje predupravljanja = 10/0.4671


Prikažimo još i povećanje reference tri puta. Parametri SLFLC bloka koje koristimo su kao i prvobitni ($K_s = 2$). Referencu prvo držimo „klasično“ tj. sokovi su od ± 4 cm, tek u $t=200$ s referenca postaje ± 12 cm od ravnotežnog položaja. Takvo ponašanje reference postigli smo sa idućim blokovima:




Slika 13: Model promjene reference



Slika 14: Odziv procesa i referentnog modela uz povećanje reference



Slika 15: Uvećan odziv procesa i referentnog modela uz povećanje reference - trenutci odmah nakon povećanja reference



Slika 16: Uvećan odziv procesa i referentnog modela uz povećanje reference - trenutci na kraju učenja

dy/e	VNE	SNE	MNE	ZE	MPE	SPE	VPE
VNDY	-0.330	-0.275	-0.120	0.132	0.054	0.000	0.000
SNDY	-0.339	-0.271	-0.064	0.134	0.197	0.000	0.000
MNDY	-0.120	-0.106	-0.288	-0.043	0.269	0.000	0.000
ZDY	-0.080	-0.091	-0.143	-0.006	0.095	0.040	0.080
MPDY	0.000	0.000	-0.248	-0.010	0.169	0.140	0.138
SPDY	0.000	0.000	-0.217	-0.262	0.030	0.248	0.299
VPDY	0.000	0.000	-0.075	-0.169	0.039	0.241	0.255

Tablica 5. Skup neizrazitih pravila nakon učenja s tri puta većom referencom

Zaključak

Cilj ove domaće zadaće je podesiti neizraziti regulator koristeći samo-učeći adaptivni sustav koji se temelji na referentnim modelom i funkcijama osjetljivosti pripadnih parametara. Koristimo SLFLC bloka u Simulinku unutar Matlab programskog okruženja, koji implementira upravo navedeni algoritam. Regulator se podešava da upravlja njemu nepoznatim sustavom, u našem slučaju sustav kuglice na platformi (iako imamo nepoznati matematički model sustava). Ovim postupkom se može na vrlo jednostavan i praktičan način dobiti dobro projektran neizraziti regulator koji će isiguravati jako dobro praćenje referentnog modela. Zanimljivo je istaknuti da jedina potrebna stvar koju moramo znati o našem sustavu je zapravo da li je statički ili astatički – što se može vrlo lako eksperimentalno dobiti. Opisani su utjecaji parametara algoritma na učenje (brzinu i efikasnost). Zadnje je napravljena provjera sa referencom koja je tri puta veća od one za koju je sustav projektiran (sa ± 4 cm na ± 12 cm). Sustav u početku ima lošiji odziv, kroz par iteracija odziv se popravljja.

Literatura

- [1] Kovačić, Z. *Inteligentni sustavi upravljanja, Upute za izradu seminarskih vježbi*. FER, ZARI, 2009, http://www.fer.unizg.hr/_download/repository/isu_seminar_upute_09_10.pdf
- [2] Kovačić, Z. i Bogdan, S., *Fuzzy Controller Design: Theory and Applications*. CRC Press, Taylor & Francis Group, 2006.
- [3] Bogdan, S., Prikaznice s predavanja na kolegiju Osnove inteligentnog upravljanja, ak. god. 2011./2012.